

**SKRIPSI**

**PENERAPAN *LONG SHORT-TERM MEMORY*  
PADA DATA *TIME SERIES* UNTUK PREDIKSI  
HARGA SAHAM PT. INDOFOOD CBP SUKSES  
MAKMUR TBK (ICBP)**



**Diajukan Oleh:**

**IRFAN CHAIRURRACHMAN**

**18106050016**

**PROGRAM STUDI TEKNIK INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI**

**UIN SUNAN KALIJAGA YOGYAKARTA**

**2022**



## PENGESAHAN TUGAS AKHIR

Nomor : B-1540/Un.02/DST/PP.00.9/07/2022

Tugas Akhir dengan judul : PENERAPAN LONG SHORT-TERM MEMORY PADA DATA TIME SERIES  
UNTUK PREDIKSI HARGA SAHAM PT. INDOFOOD CBP SUKSES MAKMUR  
TBK (ICBP)

yang dipersiapkan dan disusun oleh:

Nama : IRFAN CHAIRURRACHMAN  
Nomor Induk Mahasiswa : 18106050016  
Telah diujikan pada : Selasa, 05 Juli 2022  
Nilai ujian Tugas Akhir : A

dinyatakan telah diterima oleh Fakultas Sains dan Teknologi UIN Sunan Kalijaga Yogyakarta

### TIM UJIAN TUGAS AKHIR



Ketua Sidang  
Nurochman, S.Kom., M.Kom  
SIGNED

Valid ID: 62e0c04ada2c6



Penguji I  
Muhammad Didik Rohmad Wahyudi, S.T.,  
MT.  
SIGNED

Valid ID: 62e0a2f915fde



Penguji II  
Dr. Ir. Shofwatul 'Uyun, S.T., M.Kom.  
SIGNED

Valid ID: 62e0a6d34d7df



Yogyakarta, 05 Juli 2022  
UIN Sunan Kalijaga  
Dekan Fakultas Sains dan Teknologi  
Dr. Dra. Hj. Khurul Wardati, M.Si.  
SIGNED

Valid ID: 62e0ccde20142

### PERNYATAAN KEASLIAN SKRIPSI

Saya yang bertanda tangan di bawah ini:

Nama : Irfan Chairurrachman

NIM : 18106050016

Program Studi : Teknik Informatika

Fakultas : Sains dan Teknologi

Menyatakan bahwa skripsi saya yang berjudul "**Penerapan Long Short-Term Memory Pada Data Time Series Untuk Prediksi Harga Saham PT. Indofood CBP Sukses Makmur Tbk (ICBP)**" merupakan hasil penelitian saya sendiri, tidak terdapat pada karya yang pernah diajukan untuk memperoleh gelar sarjana di UIN Sunan Kalijaga Yogyakarta, dan bukan plagiasi karya orang lain kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Yogyakarta, 23 Juni 2022



Irfan Chairurrachman

NIM. 18106050016

## KATA PENGANTAR

Puji dan syukur saya panjatkan kepada Allah SWT yang telah memberikan rahmat dan hidayahnya sehingga penulis dapat menyelesaikan penelitian dan penyusunan skripsi ini dengan judul “Penerapan *Long Short-Term Memory* Pada Data *Time Series* Untuk Prediksi Harga Saham PT. Indofood CBP Sukses Makmur Tbk (ICBP)” dengan baik. Sholawat dan salam selalu tercurahkan kepada junjungan kita Rasulullah SAW, yang telah menuntun kita menuju ke zaman yang terang benderang, dan semoga kita semua mendapatkan syafaat di hari kiamat kelak.

Tidak dapat disangkal bahwa butuh usaha yang keras dalam penyelesaian pengerjaan skripsi ini. Namun Skripsi dalam proses penyelesaiannya tidak lepas dari bantuan dan dukungan dari berbagai pihak baik secara langsung maupun tidak langsung. Secara spesifik, penulis ingin mengucapkan terima kasih kepada:

1. Kedua orang tua, ayah, Ir. Zulman Wardi M.Si., dan ibu, Yenni Suryati yang telah membesarkan dan merawat penulis hingga dapat mengenyam pendidikan tinggi dan menjadi pribadi yang lebih baik setiap waktunya serta saudara dan saudari penulis yang selalu memberikan dukungan langsung maupun tidak langsung selama berkuliah di Yogyakarta.
2. Bapak Nurochman, S.Kom., M.Kom. selaku dosen pembimbing tugas akhir yang selalu memberikan arahan, ilmu serta motivasi kepada penulis selama pengerjaan tugas akhir.
3. Ir. Muhammad Taufiq Nuruzzaman, S.T., M.Eng., Ph.D. selaku dosen pendamping akademik selama berkuliah di Teknik Informatika UIN Sunan Kalijaga.
4. Seluruh dosen dan karyawan program studi Teknik Informatika UIN Sunan Kalijaga Yogyakarta yang telah memberi ilmu dan bantuan selama masa studi kuliah penulis.
5. Teman-teman The Kongs atau teman-teman kontrakan, yaitu Cholish, Shamil, Fakhry, Galih, Nawwab dan Uqi yang senantiasa berbagi cerita,

pengalaman, rezeki serta dukungan terhadap satu sama lain di daerah perantauan.

6. Nadhifa Aqilla Husna dan Fahira Nurul Ichzza yang selalu memberikan dukungan terhadap berbagai permasalahan khususnya dukungan untuk selalu mencapai cita-cita dalam bidang data sains dan akademik.
7. Kawan-kawan DEV yang telah memotivasi untuk belajar coding sejak awal kuliah.
8. Teman-teman MIA 1 MAN 2 Makassar, seperti Habib, Fida, dan Fasha yang tetap mendukung dan menemani hingga masa kuliah.
9. Teman-teman Teknik Informatika lintas angkatan yang telah menjadi rekan selama masa perkuliahan, terutama kawan-kawan angkatan 2018.
10. Teman-teman yang tidak dapat disebutkan satu persatu yang telah membantu memberikan dukungan.

Penulis menyadari masih banyak kekurangan dalam skripsi ini, sehingga kritik dan saran yang membangun dari pembaca sangat penulis harapkan. Semoga tugas akhir ini dapat memberikan manfaat untuk mendorong penelitian-penelitian selanjutnya.

Yogyakarta, Juni 2022

Penyusun

Irfan Chairurrachman

18106050016

## **HALAMAN PERSEMBAHAN**

Saya persembahkan tugas akhir ini untuk kedua orang tua saya yang telah berjuang untuk mendidik dan merawat saya sampai detik ini.

## **MOTTO**

*“Don’t practice until you get it right, practice until you never get it wrong”*

“Bakat yang sebenarnya adalah saat kita tidak pernah menyerah”

**- Dikutip dari iklan Surya Pro 2016 -**

## DAFTAR ISI

HALAMAN JUDUL.....	i
HALAMAN PENGESAHAN.....	ii
SURAT PERNYATAAN KEASLIAN.....	iii
KATA PENGANTAR .....	iii
HALAMAN PERSEMBAHAN .....	vi
MOTTO .....	vii
DAFTAR ISI.....	viii
DAFTAR TABEL.....	xi
DAFTAR GAMBAR .....	xii
INTISARI.....	xiii
ABSTRACT.....	xiv
BAB I PENDAHULUAN .....	1
1.1 Latar Belakang .....	1
1.2 Rumusan Masalah .....	2
1.3 Tujuan Penelitian .....	2
1.4 Batasan Masalah.....	3
1.5 Manfaat Penelitian .....	4
1.6 Keaslian Penelitian.....	4
BAB II TINJAUAN PUSTAKA DAN LANDASAN TEORI .....	5
2.1 Tinjauan Pustaka .....	5



2.2 Landasan Teori.....	10
2.2.1 Data .....	10
2.2.2 Normalisasi.....	10
2.2.3 Neural Network .....	11
2.2.4 Long <i>Short-Term Memory</i> (LSTM) .....	12
2.2.5 Vanilla LSTM.....	13
2.2.6 CNN-LSTM.....	14
2.2.7 <i>Bidirectional LSTM</i> .....	15
2.2.8 Denormalisasi .....	16
BAB III METODE PENELITIAN.....	19
3.1 Alat dan Bahan.....	19
3.2 Obyek Penelitian .....	19
3.3 Langkah-langkah Penelitian.....	19
BAB IV HASIL DAN PEMBAHASAN .....	22
4.1 Studi Pustaka dan Pengumpulan Data .....	22
4.2 <i>Preprocessing Data</i> .....	24
4.2.1 Normalisasi.....	24
4.2.2 Pembagian Data Latih dan Data Uji.....	24
4.2.3 Struktur Pola <i>Time Series</i> .....	26
4.3 Struktur Jaringan Syaraf Tiruan .....	27
4.3.1 <i>Vanilla LSTM</i> .....	27

4.3.2	CNN-LSTM.....	29
4.3.3	<i>Bidirectional</i> LSTM .....	30
4.4	Proses Percobaan dan Pelatihan .....	31
4.4.1	<i>Vanilla</i> LSTM.....	31
4.4.2	CNN-LSTM.....	35
4.4.3	Bidirectional-LSTM .....	39
4.5	Proses Pengujian .....	43
4.5.1	<i>Vanilla</i> LSTM.....	43
4.5.2	CNN LSTM.....	44
4.5.3	Bidirectional LSTM .....	45
4.6	Analisis Model Terbaik.....	47
BAB V	PENUTUP.....	50
5.1	Kesimpulan .....	50
5.2	Saran.....	51
DAFTAR	PUSTAKA .....	52

## DAFTAR TABEL

Tabel 2. 1 Tinjauan Pustaka .....	7
Tabel 4. 1 Harga penutupan harian saham ICBP.....	23
Tabel 4. 2 Pembagian data latih dan data uji.....	25
Tabel 4. 3 Pola <i>time series</i> .....	27
Tabel 4. 4 Hasil <i>hyperparameter tuning vanilla</i> LSTM .....	32
Tabel 4. 5 Performa <i>vanilla</i> LSTM terhadap data latih ternormalisasi .....	33
Tabel 4. 6 Performa <i>vanilla</i> LSTM terhadap data latih aktual .....	34
Tabel 4. 7 Hasil <i>hyperparameter tuning CNN-LSTM</i> .....	35
Tabel 4. 8 Performa CNN-LSTM terhadap data latih ternormalisasi .....	37
Tabel 4. 9 Performa CNN-LSTM terhadap data latih aktual.....	38
Tabel 4. 10 Hasil <i>hyperparameter tuning bidirectional</i> LSTM.....	39
Tabel 4. 11 Performa <i>bidirectional</i> LSTM terhadap data latih ternormalisasi.....	41
Tabel 4. 12 Performa <i>bidirectional</i> LSTM terhadap data latih aktual.....	41
Tabel 4. 13 Perbandingan performa tiga jenis LSTM terbaik terhadap data latih.....	42
Tabel 4. 14 Performa <i>vanilla</i> LSTM terhadap data uji.....	43
Tabel 4. 15 Performa CNN-LSTM terhadap data uji.....	44
Tabel 4. 16 Performa model terhadap data uji.....	45
Tabel 4. 17 Performa 3 jenis LSTM terbaik terhadap data uji .....	46
Tabel 4. 18 Permutation importance CNN-LSTM 70:30 menggunakan metrik $R^2$ .....	48
Tabel 4. 19 Permutation importance CNN-LSTM 60:40 menggunakan metrik $R^2$ .....	49

## DAFTAR GAMBAR

Gambar 2. 1 Ilustrasi <i>neuron</i> dan model matematikanya .....	11
Gambar 2. 2 Fungsi Sigmoid dan Tanh.....	12
Gambar 2. 3 Fungsi ReLu.....	12
Gambar 2. 4 Arsitektur <i>Long Short-Term Memory</i> (LSTM) .....	13
Gambar 2. 5 Contoh operasi kernel 1 dimensi .....	15
Gambar 2. 6 Struktur dasar dari <i>bidirectional</i> LSTM.....	16
Gambar 3. 1 Langkah-langkah penelitian .....	21
Gambar 4. 1 Grafik pergerakan harga saham ICBP .....	22
Gambar 4. 2 Ilustrasi pola <i>time series</i> .....	26
Gambar 4. 3 Struktur jaringan <i>vanilla</i> LSTM .....	28
Gambar 4. 4 Struktur jaringan CNN-LSTM .....	29
Gambar 4. 5 Struktur jaringan <i>bidirectional</i> LSTM.....	30
Gambar 4. 6 Arsitektur vanilla LSTM dengan <i>hyperparameter</i> terbaik.....	33
Gambar 4. 7 Perbandingan latih aktual dan prediksi vanilla LSTM .....	35
Gambar 4. 8 Arsitektur CNN-LSTM dengan <i>hyperparameter</i> terbaik.....	37
Gambar 4. 9 Perbandingan data latih aktual dan prediksi CNN-LSTM .....	38
Gambar 4. 10 Arsitektur <i>bidirectional</i> LSTM dengan <i>hyperparameter</i> terbaik.....	40
Gambar 4. 11 Perbandingan data latih aktual dengan prediksi <i>bidirectional</i> LSTM ..	42
Gambar 4. 12 Perbandingan data uji dengan prediksi <i>vanilla</i> LSTM .....	44
Gambar 4. 13 Perbandingan data uji dengan prediksi CNN-LSTM .....	45
Gambar 4. 14 Perbandingan data uji dengan prediksi.....	46

**PENERAPAN *LONG SHORT-TERM MEMORY* PADA DATA TIME  
SERIES UNTUK PREDIKSI HARGA SAHAM PT. INDOFOOD CBP  
SUKSES MAKMUR TBK (ICBP)**

**Irfan Chairurrachman**

**18106050016**

**INTISARI**

Dalam dunia *trading*, prediksi saham memainkan peran penting dalam mengembangkan strategi *trading* yang efektif untuk mencapai keuntungan yang maksimum. Belakangan ini, *deep learning*, khususnya *long short-term memory* (LSTM) telah dirancang untuk bekerja dengan prediksi urutan. Keunggulan LSTM terletak pada kemampuan menangani masalah *exploding/vanishing gradient*. Dalam penelitian ini, tiga jenis LSTM yang digunakan bernama *vanilla* LSTM, CNN-LSTM, *bidirectional* LSTM dibandingkan untuk memprediksi suatu saham, lebih tepatnya harga saham ICBP (PT. Indofood CBP Sukses Makmur). Hasil penelitian menunjukkan CNN-LSTM adalah jenis LSTM terbaik dengan nilai MAE dan  $R^2$  berurutan sebesar 74.1365 dan 96,6%.

**Kata kunci:** *LSTM, vanilla, CNN-LSTM, bidirectional-LSTM, ICBP, saham*

**LONG SHORT-TERM MEMORY IMPLEMENTATION ON TIME  
SERIES DATA FOR PT. INDOFOOD CBP SUKSES MAKMUR TBK  
(ICBP) STOCK PREDICTION**

**Irfan Chairurrachman**

**18106050016**

**ABSTRACT**

In trading, stock prediction plays an important role in developing an effective trading strategy to achieve a maximum return. Recently, deep learning, specifically Long Short-Term Memory (LSTM) has been designed to work with sequence prediction. The advantage of LSTM lies in the ability to handle the exploding / vanishing gradient problem. In this research, three types of LSTM namely vanilla LSTM, CNN-LSTM, and bidirectional LSTM were compared to predict a stock, more specifically ICBP stock prices (PT. Indofood CBP Sukses Makmur). The results showed that CNN-LSTM was the best type of LSTM with MAE and  $R^2$  values were 74,1365 and 96,6% respectively.

**Keywords:** LSTM, vanilla, CNN-LSTM, bidirectional-LSTM, ICBP, stock

## **BAB I**

### **PENDAHULUAN**

#### **1.1 Latar Belakang**

Saham adalah surat berharga yang menjadi bukti seseorang atau badan memiliki bagian modal terhadap suatu perusahaan. Saham dikeluarkan oleh sebuah perusahaan yang berbentuk Perseroan Terbatas (PT) atau yang biasa disebut emiten. Penerbitan saham merupakan salah satu cara agar perusahaan mendapatkan modal atau dana segar untuk pengembangan bisnis secara jangka panjang. Saham sendiri dapat diperjualbelikan melalui Bursa Efek dengan harga yang berubah-ubah sesuai kondisi perusahaan dan kondisi ekonomi.

PT Indofood CBP (*Consumer Branded Product*) Sukses Makmur Tbk (ICBP) atau lebih dikenal dengan Indofood CBP merupakan produsen berbagai jenis makanan dan minuman yang bermarkas di Jakarta, Indonesia. Perusahaan ini didirikan pada 2 September 2009 dan dimaksudkan sebagai anak usaha PT Indofood Sukses Makmur (INDF) Tbk yang memegang industri makanan dan minuman. Dinamakan CBP karena memang produknya merupakan barang langsung jadi yang akan langsung dijual ke konsumen. Pada 7 Oktober 2010, perusahaan ini resmi mencatatkan sahamnya di Bursa Efek Indonesia dengan harga IPO sebesar Rp5.395,00/saham. Dalam pencatatan ini, ICBP melepaskan 20% sahamnya ke publik, dan mendapatkan dana sebesar Rp 6 triliun.

Peramalan (*forecasting*) adalah seni dan ilmu untuk memperkirakan kejadian di masa depan. Hal ini dapat dilakukan dengan melibatkan data historis dan memproyeksikannya ke masa mendatang. Dengan cara membentuk model matematis untuk mencapai akurasi proyeksi yang ideal. Peramalan harga saham di masa depan sangat dibutuhkan oleh investor demi meraih keuntungan sebanyak mungkin dan

meminimalkan kerugian. Proses peramalan harus mengupayakan keakuratan hasil peramalan, meskipun akan ada ketidakpastian dari perusahaan saham tertentu. Maka dibutuhkan pemodelan terbaik untuk prediksi harga saham.

Dalam memprediksi harga saham, mayoritas investor menggunakan analisis teknikal, yaitu prediksi saham berdasarkan data historis harga saham. Salah satu metode yang digunakan adalah ARIMA (*Auto Regressive Integrated Moving Average*), ARIMA dapat memprediksi saham dengan keakuratan prediksi sebesar 83% (Fatra, 2021).

Dalam meningkatkan akurasi prediksi harga saham, salah satu metode prediksi yang dapat digunakan yaitu melakukan prediksi menggunakan *deep learning* khususnya menggunakan *Long Short-Term Memory* dalam memprediksi harga saham ICBP. Semakin tinggi keakuratan prediksi saham maka semakin menguntungkan bagi investor.

## **1.2 Rumusan Masalah**

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah yang akan diselesaikan dalam penelitian ini yaitu bagaimana menentukan struktur jaringan syaraf tiruan terbaik dan presentasi pembagian data latih daata uji dengan menerapkan berbagai jenis LSTM untuk peramalan harga saham PT. Indofood CBP Sukses Makmur Tbk (ICBP).

## **1.3 Tujuan Penelitian**

Tujuan dari penelitian ini yaitu sebagai berikut.

1. Melakukan analisis teknikal dengan menerapkan LSTM pada jaringan syaraf tiruan untuk prediksi harga saham ICBP.



2. Mencari struktur yang dan jenis LSTM terbaik untuk prediksi harga saham ICBP dengan menerapkan tiga jenis LSTM: *vanilla* LSTM, CNN-LSTM, *bidirectional* LSTM.
3. Mencari *hyperparameter* terbaik menggunakan *hyperparameter tuning* yang diterapkan pada struktur jaringan syaraf tiruan dengan metode LSTM untuk prediksi saham ICBP.
4. Mencari kombinasi pembagian data latih dan data uji terbaik dalam pembangunan model LSTM untuk prediksi saham ICBP.

#### 1.4 Batasan Masalah

Pada penelitian ini didefinisikan beberapa batasan sebagai berikut:

1. Data yang dipakai sebagai masukan yaitu data harga saham dari emiten PT. Indofood CBP Sukses Makmur Tbk (ICBP).
2. Jenis LSTM yang digunakan adalah *vanilla* LSTM, CNN-LSTM, dan *bidirectional* LSTM.
3. *Hyperparameter* yang digunakan untuk *hyperparameter tuning* antara lain:
  - a. *Neuron hidden*: 32 hingga 512 dengan kelipatan 32.
  - b. *learning rate*: 0,01, 0,001, 0,0001
4. Jumlah epoch untuk *hyperparameter tuning* dan pelatihan adalah 50 epoch.
5. Kombinasi pembagian data latih dan data uji antara lain:
  - a. 80% data latih dan 20% data uji
  - b. 70% data latih dan 30% data uji
  - c. 60% data latih dan 40% data uji

### **1.5 Manfaat Penelitian**

Penelitian ini diharapkan dapat membantu para investor untuk menjadi referensi dalam analisis teknikal dalam mengambil keputusan pembelian atau penjualan saham ICBP. Penelitian ini juga diharapkan dapat membantu pembaca dan peneliti mengetahui performa metode LSTM dalam prediksi saham ICBP.

### **1.6 Keaslian Penelitian**

Keaslian penelitian ini diperlukan sebagai bukti agar tidak plagiarisme berdasarkan beberapa penelitian terdahulu yang mempunyai karakteristik yang sama dalam hal metode, namun berbeda secara objek penelitian.

## BAB II

### TINJAUAN PUSTAKA DAN LANDASAN TEORI

#### 2.1 Tinjauan Pustaka

Arsitektur neural network seperti *Long Short-Term Memory* (LSTM) sudah banyak dianalisis secara terpisah dengan masing-masing studi kasus dan hasil yang berbeda. Pada bab ini dilakukan pencarian referensi, pengumpulan data hasil penelitian yang terkait.

Pada penelitian yang dilakukan oleh Sabar Sautomo dan Hilman Ferdinandus (2021) menunjukkan model LSTM dengan menggunakan tiga *hidden layers* dan hyperparameter yang tepat dapat menghasilkan performa *Mean Square Error* (MSE) sebesar 0.2325, *Root Mean Square Error* (RMSE) sebesar 0.482, *Mean Average Error* (MAE) sebesar 0.3292 dan *Mean Average Percentage Error* (MAPE) sebesar 0.4214. Ini lebih baik dibandingkan pemodelan konvensional menggunakan *Autoregressive Integrated Moving Average* (ARIMA) sebagai model pembanding..

Menurut M. Rizki, S. Basuki dan Y. Azhar (2020) dalam penelitiannya untuk model LSTM dengan jumlah epoch 150 serta pembagian data train 50% dan data test 50% menunjukkan hasil *Root Mean Square Error* (RMSE) sebesar 12.079 pada data train dan 11.288 pada data test.

Penelitian yang dilakukan. Cahyadi, A. Damayanti dan D. Aryadani (2020) Menunjukkan sistem dapat mengklasifikasi sentimen. Tingkat akurasi pengujian didapatkan sebesar 65% dan tingkat akurasi penerapan sebesar 79,46%. Secara ringkas tinjauan terhadap penelitian terdahulu disajikan dalam Tabel 2.1.

Pada penelitian ini akan berfokus terhadap penggunaan serta pencarian struktur LSTM terbaik dalam memprediksi data *time series* dalam hal ini adalah saham ICBP.

Tabel 2. 1 Tinjauan Pustaka

No	Peneliti	Studi Kasus	Metode	Hasil
1.	(Sabar Sautomo, Hilman Ferdinandus 2021)	Prediksi Belanja Pemerintah Indonesia Menggunakan Long Short-Term Memory (LSTM)	LSTM	<p>Eksperimen menunjukkan model LSTM dengan menggunakan tiga hidden layers dan hyperparameter yang tepat dapat menghasilkan performa Mean Square Error (MSE) sebesar 0.2325, Root Mean Square Error (RMSE) sebesar 0.482, Mean Average Error (MAE) sebesar 0.3292 dan Mean Average Percentage Error (MAPE) sebesar 0.4214.</p> <p>Ini lebih baik dibandingkan pemodelan konvensional menggunakan Autoregressive Integrated Moving Average (ARIMA) sebagai model pembanding.</p>

2.	(M. Rizki, S. Basuki, Y. Azhar, 2020)	Implementasi Deep Learning Menggunakan Arsitektur Long Short Term Memory (LSTM) Untuk Prediksi Curah Hujan Kota Malang	LSTM	Pelatihan model LSTM dengan jumlah epoch 150 serta pembagian data train 50% dan data test 50% menunjukkan hasil Root Mean Square Error (RMSE) sebesar 12.079 pada data train dan 11.288 pada data test.
3.	(R. Cahyadi, A. Damayanti, D. Aryadani, 2020)	Recurrent Neural Network (RNN) dengan Long Short Term Memory (LSTM) untuk analisis sentimen data instagram	LSTM, RNN	Hasil penelitian ini menunjukkan sistem dapat mengklasifikasi sentimen. Tingkat akurasi pengujian didapatkan sebesar 65% dan tingkat akurasi penerapan sebesar 79,46%.
4.	(L. Wiranda, M. Sadikin, 2019)	Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma	LSTM	Hasil penelitian melalui evaluasi kinerja model data training terhadap data testing, menunjukkan bahwa nilai LSTM dalam memprediksi penjualan

				sebesar 13,762,154.00 pada RMSE dalam nilai rupiah dan MAPE sebesar 12%.
5.	(B.A. Aprisan, Y. Azhar, V.R.S. Nastiti, 2020).	Prediksi Pendapatan Kargo Menggunakan Arsitektur Long Short Term Memory	LSTM	Hasil penelitian ini menunjukkan hasil prediksi terbaik yaitu pada komposisi data train 90% dan data test 10% dengan nilai RMSE untuk data train sebesar 641,375.70 dan data test 594,197.70.

## 2.2 Landasan Teori

### 2.2.1 Data

Dalam dunia saham, sangat penting bagi investor untuk mengetahui harga saham suatu emiten kedepannya demi mencapai keuntungan maksimum. Dalam memprediksi masa depan, dibutuhkan pemodelan matematis berdasarkan data historis untuk memproyeksikan hasil prediksi kedepannya. Pemodelan matematis ini diharapkan mencapai hasil yang paling optimal. Maka dari itu sangat penting adanya sumber data yang relevan dan baik demi memproyeksikan harga saham di masa depan.

Data yang digunakan berasal Yahoo Finance dengan data saham ICBP dari tanggal 25 September 2019 hingga 24 September 2021 yang diunduh dalam bentuk csv. Data ini selanjutnya diolah agar model dapat memprediksi harga saham selanjutnya.

Data *time series* didefinisikan sebagai kumpulan observasi atau amatan yang dibuat secara beruntun (*sequentially*) atau berurut sepanjang waktu (Sumarjaya, 2016). Dalam kasus ini yaitu data saham ICBP dikategorikan sebagai data *time series*, karena data harga saham ICBP dicatat setiap waktu (bisa harian atau mingguan) namun hanya terfokus pada satu nilai saja, yaitu harga saham ICBP.

### 2.2.2 Normalisasi

Dalam rangka meminimalkan error perlu dilakukan normalisasi pada dataset dengan mengubah nilai aktual menjadi nilai dengan range antara [0,1]. Teknik normalisasi juga digunakan untuk merubah ukuran data menjadi lebih kecil tanpa merubah informasi penting pada data tersebut. Teknik normalisasi yang digunakan adalah *min-max scaling*. Dibawah ini adalah rumus untuk normalisasi menggunakan *min-max scaling*.

$$X' = \frac{X - \min(x)}{\max(x) - \min(x)} \quad (2.1)$$



Keterangan:

$X'$  = Nilai hasil normalisasi


$X$  = Nilai aktual yang akan dinormalisasikan

$\min(x)$  = Nilai minimum dari keseluruhan data

$\max(x)$  = Nilai maksimum dari keseluruhan data

### 2.2.3 Neural Network

*Neural Network* (NN) terinspirasi dari bagaimana neuron dalam otak manusia bekerja. Tiap neuron dalam otak manusia saling berhubungan dan informasi mengalir dari setiap neuron tersebut. Gambar 2.1 menunjukkan ilustrasi neuron dengan model matematikanya.




Gambar 2. 1 Ilustrasi *neuron* dan model matematikanya


*Neural network* terdiri dari susunan-susunan neuron (biasa disebut unit) yang membentuk suatu lapisan dan lapisan neuron terhubung ke lapisan neuron lainnya. Walaupun setiap unit mengimplementasikan transformasi yang lumayan simpel untuk nilai masukannya. Namun, fungsi yang diwakili dari keseluruhan operasi jaringan NN dapat menjadi sangat kompleks (Goodfellow dan Bengio, 2016).

Fungsi aktivasi sendiri berfungsi untuk menentukan apakah neuron tersebut harus “aktif” atau tidak berdasarkan dari weighted sum dari input. Secara umum terdapat 2 jenis *activation function*, *Linear* dan *Nonlinear Activation function*. Dalam proyek ini, fungsi aktivasi yang akan digunakan adalah *Non-Linear Activation function* karena *time series* adalah hal yang kompleks. Ada beberapa fungsi non-linear yang banyak digunakan dalam

klasifikasi dua kelas diantaranya Sigmoid, fungsi Tanh seperti Gambar 2.2, serta ReLu seperti Gambar 2.3.



Gambar 2. 2 Fungsi Sigmoid dan Tanh




Gambar 2. 3 Fungsi ReLu

#### 2.2.4 Long Short-Term Memory (LSTM)

Dalam penelitian ini, digunakan arsitektur *Long Short-Term Memory* (LSTM). LSTM pertama kali disebutkan pertama kali pada tahun

1997 oleh Hochreiter dan Schmidhuber. LSTM disebut juga sebagai jaringan syaraf tiruan dengan arsitektur yang mudah beradaptasi, sehingga bentuknya dapat disesuaikan, tergantung aplikasinya. LSTM merupakan turunan dari metode *Recurrent Neural Network* yang merupakan jaringan syaraf berulang yang didesain khusus untuk menangani data berurutan (*sequence data*). Namun RNN mempunyai masalah *vanishing* dan *exploding gradient* yaitu apabila terjadi perubahan pada jangkauan nilai dari satu lapisan menuju lapisan berikutnya pada sebuah arsitektur.

LSTM dibangun dan dirancang untuk mengatasi masalah gradien menghilang dari RNN ketika berhadapan dengan *vanishing* dan *exploding gradient* tersebut (Ta et al., 2020). Arsitektur LSTM terdiri dari lapisan input, lapisan output, dan lapisan tersembunyi yang disajikan pada Gambar 2.4.



Gambar 2. 4 Arsitektur *Long Short-Term Memory* (LSTM)

### 2.2.5 Vanilla LSTM

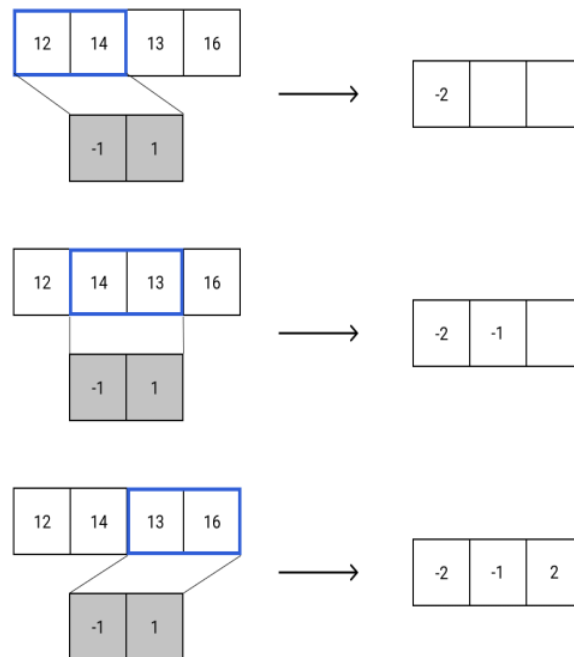
*Vanilla* LSTM terdiri dari sebuah *cell*, sebuah *input gate*, sebuah *output gate* dan sebuah *forget gate*. Pada awalnya *forget gate* tidak termasuk di bagian arsitektur LSTM, namun kemudian diajukan oleh Gers et al. agar jaringan dapat menyetel ulang keadaan jaringan. *Cell* mengingat nilai selama interval waktu yang diinginkan dan tiga *gate* yang lain mengatur alur dari informasi yang berkaitan dengan *cell*. Secara singkat, *vanilla* LSTM adalah sebuah arsitektur yang hanya menggunakan jaringan LSTM. *Vanilla* LSTM masih salah satu jaringan yang paling populer

sebagai jaringan yang dipilih, walaupun sangat memungkinkan untuk mengkombinasikan dan mengembangkan jaringan LSTM untuk membentuk model *hybrid* seperti halnya CNN-LSTM dan Bidirectional LSTM (Van et al., 2020).

#### 2.2.6 CNN-LSTM

CNN LSTM menggunakan layer CNN (*Convolutional Neural Network*) yang dicetuskan oleh Lecun et al., (1998), mulanya digunakan untuk mengotomasi ekstraksi fitur pada data citra. Sebelum CNN diperkenalkan, banyak waktu yang dibutuhkan yang dihabiskan untuk ekstraksi fitur, Kemampuan belajar yang kuat dari CNN sebagian besar disebabkan oleh penggunaan beberapa tahap ekstraksi fitur pada lapisan tersembunyi yang dapat secara otomatis mempelajari representasi data (Prasetyawan and 'Uyun, 2020). Lapisan konvolusi pada CNN terdiri beberapa kernel konvolusi dengan ukuran tertentu. Cara kerja CNN adalah dengan melakukan perkalian dot terhadap sub-data, kernel kemudian digeser sebanyak  $n$  langkah untuk melakukan operasi terhadap sub data lainnya hingga dilakukan operasi terhadap seluruh matriks data.

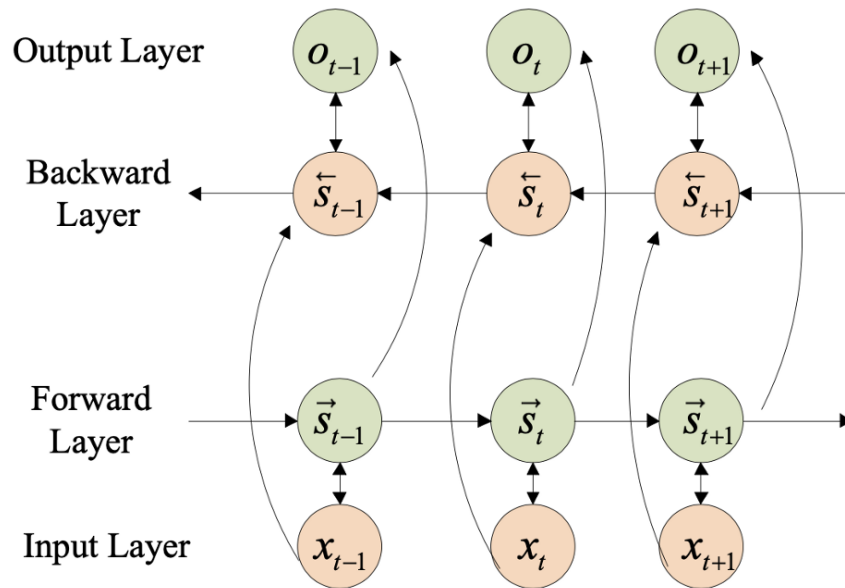
Umumnya CNN dilakukan terhadap data 2 dimensi seperti matriks citra, namun CNN juga dapat digunakan terhadap data 1 dimensi seperti dalam penelitian ini adalah data *time series* saham ICBP yang kemudian hasil *layer* CNN dilanjutkan dengan melewati *layer* LSTM, penggabungan arsitektur ini biasa disebut CNN-LSTM. Berikut ditampilkan pada Gambar 2.5 mengilustrasikan bagaimana data  $1 \times 4$  yang dikenakan kernel konvolusi dengan lebar  $1 \times 2$  dan panjang langkah 1.



Gambar 2. 5 Contoh operasi kernel 1 dimensi

### 2.2.7 *Bidirectional LSTM*

Bidirectional LSTM adalah pengembangan dari LSTM dimana dua LSTM diaplikasikan terhadap data *input*. Bidirectional LSTM dilatih bukan hanya melalui *input* terhadap *output*, namun juga *output* terhadap *input*. Pada tahap pertama, sebuah LSTM diaplikasikan terhadap data input berurutan (yaitu *forward layer*). Pada tahap kedua, bentuk terbalik dari urutan input dimasukkan ke dalam LSTM model (yaitu *backward layer*, atau Watson-Crick *complement*). Menerapkan LSTM sebanyak dua kali diharapkan berdampak dalam meningkatkan pembelajaran *long-term dependencies* yang juga berakibat dalam peningkatan akurasi model. (Siarni-Namini et al., 2019).



Gambar 2. 6 Struktur dasar dari *bidirectional* LSTM

Pada Gambar 2.6 terlihat bahwa *forward layer* menghitung secara maju dari 1 hingga  $t$ , dan menyimpan *output* dari *forward hidden layer* pada tiap masing-masing waktu. *Backward layer* menghitung data *time series* terbalik dan menyimpan *output* dari *backward hidden layer* pada tiap masing-masing waktunya. Pada akhirnya, *output* dari *bidirectional LSTM* dihitung dengan menggabungkan nilai-nilai yang berkaitan dari hasil *output forward layer* dan *backward layer* pada tiap masing-masing waktunya (Cai et al., 2021)

### 2.2.8 Denormalisasi

Setelah mendapatkan hasil prediksi dari model LSTM. Maka, sebelum menghitung hasil prediksi perlu dilakukan teknik denormalisasi. Denormalisasi adalah proses mengembalikan nilai yang telah ternormalisasi, yaitu nilai dengan rentang  $[0,1]$  menjadi nilai aktual seperti pada dataset. Tujuan dilakukannya denormalisasi adalah agar nilai lebih mudah dibaca dan dimengerti karena sesuai dengan rentang nilai pada dataset yang digunakan. Dibawah ini adalah rumus untuk denormalisasi.

$$X = X'(\max(x) - \min(x)) + \min(x) \quad (2.2)$$

Keterangan:

X = Nilai hasil denormalisasi

X` = Nilai hasil normalisasi

min(x) = Nilai minimum dari keseluruhan data

max(x) = Nilai maksimum dari keseluruhan data

### 2.2.1 Mean Square Error (MSE)

*Mean Square Error* digunakan untuk menghitung nilai error set pembelajaran dengan hasil ideal yang ditentukan sebelumnya. MSE adalah rata-rata kesalahan kuadrat antara nilai aktual dan nilai prediksi. Nilai MSE yang rendah atau mendekati nol menunjukkan bahwa hasil peramalan sesuai dengan data aktual dan bisa dijadikan untuk perhitungan prediksi di periode mendatang. Persamaan 2.3 adalah rumus untuk menghitung MSE.

$$MSE = \frac{\sum_{t=1}^n (A_t - F_t)^2}{n} \quad (2.3)$$

Keterangan:

A<sub>t</sub> = Nilai Aktual

F<sub>t</sub> = Nilai hasil prediksi

n = banyaknya data

### 2.2.9 Mean Absolute Error (MAE)

*Mean Absolute Error* (MAE) adalah rata-rata selisih mutlak nilai sebenarnya (aktual) dengan nilai prediksi. MAE digunakan untuk mengukur keakuratan suatu model statistik dalam melakukan prediksi. Semakin kecil nilai MAE semakin baik model tersebut dalam melakukan peramalan. Rumus perhitungan MAE dapat dilihat pada Persamaan 2.4.

$$MAE = \frac{1}{n} \sum_{t=1}^n |At - Ft| \quad (2.4)$$

Keterangan:

At = Nilai aktual

Ft = Nilai hasil prediksi

n = banyaknya data

### 2.2.1 *R-squared* ( $R^2$ )

*R-squared* ( $R^2$ ) disebut juga sebagai koefisien determinasi yang menjelaskan seberapa jauh data dependen dapat dijelaskan oleh data independen.  $R^2$  bernilai antara 0-1 dengan ketentuan semakin mendekati angka satu berarti semakin baik. Jika  $R^2$  bernilai 0.6, berarti 60% sebaran variabel dependen dapat dijelaskan oleh variabel independen. Sisanya 40% tidak dapat dijelaskan oleh variabel independen atau dapat dijelaskan oleh variabel diluar variabel independen (komponen error). Maka dari itu, semakin besar nilai  $R^2$  maka semakin bagus performa model tersebut karena semakin besar variabel dependen dapat dijelaskan oleh variabel independen. Rumus  $R^2$  dijabarkan oleh Persamaan 2.5.

$$R^2 = 1 - \frac{RSS}{TSS} \quad (2.5)$$

Keterangan:

$R^2$  = Koefisiend determinasi

RSS = Variansi yang tidak dapat dijelaskan

TSS = Total Variansi



## BAB III

### METODE PENELITIAN

#### 3.1 Alat dan Bahan

- a. Bahasa Pemrograman Python
- b. Jupyter Notebook
- c. Google Colaboratory
- d. Library Python: sklearn, Pandas, tensorflow, Keras.
- e. Dataset saham ICBP dari tanggal 3 April 2017 - 1 April 2022.

#### 3.2 Obyek Penelitian

Objek penelitian adalah penerapan *Long Short-Term Memory* (LSTM) dalam peramalan harga saham PT. Indofood CBP Sukses Makmur Tbk.

#### 3.3 Langkah-langkah Penelitian

1. Studi Pustaka dan Pengumpulan Data

Peneliti melakukan studi pustaka dengan mempelajari literatur-literatur yang sudah ada yaitu dengan membaca jurnal ilmiah, situs web, video pembelajaran, serta forum diskusi. Dilakukannya studi pustaka dengan tujuan untuk melakukan pengkajian penelitian yang menggunakan metode yang sama dengan objek yang berbeda, ataupun objek yang sama tetapi menggunakan metode yang berbeda yang nantinya akan dibandingkan dengan hasil penelitian ini.

Pengkajian juga dilakukan untuk mengetahui metode pemrosesan apa saja yang digunakan serta mengumpulkan informasi terhadap hal teknis mengenai implementasi yang baik untuk data yang bersifat *time-series*.

Sumber data yang digunakan pada penelitian kali ini adalah data dengan kode saham ICBP dari tanggal 1 April 2017 hingga 3 April 2022 yang bersumber dari yahoo finance yang dapat diunduh pada link berikut <https://finance.yahoo.com/quote/ICBP.JK/history?p=ICBP.JK>.

## 2. *Data Preprocessing*

Tahapan-tahapan *data preprocessing* adalah sebagai berikut:

- a. Normalisasi data menggunakan Persamaan 2.1 dengan rentang  $[0,1]$ .
  - b. Pembagian data menjadi data latih dan data uji. Pembagian ini dilakukan dengan 3 kombinasi, yaitu dengan perbandingan 80:20, 70:30, dan terakhir 60:40. Perbandingan terbesar untuk setiap kombinasi selalu diacu untuk data latih.
  - c. Pembentukan pola *time-series* sebagai data input. Setiap data input memiliki pasangan target. Pada penelitian kali ini, pola yang dibentuk adalah untuk setiap lima urutan data input, memiliki satu data target untuk urutan ke-enamnya.
3. Pembentukan Arsitektur Jaringan dan *Hyperparameter Tuning*.

Pada proses ini dibentuk tiga jenis arsitektur LSTM, yaitu:

### a. *Vanilla LSTM*

*Vanilla LSTM* terdiri dari layer masukan untuk 5 data input dan 1 data target, 1 *hidden layer* untuk *LSTM layer* kemudian 1 layer keluaran untuk memprediksi hasil masukan.

### b. *CNN-LSTM*

Seperti pada *Vanilla LSTM*, *CNN-LSTM* terdiri dari layer masukan untuk 5 data input dan 1 data target, namun setelah itu terdapat 1 layer CNN 1 dimensi untuk mengekstrak fitur penting pada urutan data input, kemudian bobot dilanjutkan ke layer *LSTM* untuk mengolah bobot yang akan dikirimkan ke *output layer* sebagai hasil prediksi dari data masukan.

### c. *Bidirectional LSTM*

*Bidirectional LSTM* juga mempunyai layer masukan seperti pada *Vanilla LSTM* dan *CNN LSTM*. Layer selanjutnya adalah layer *bidirectional lstm* yang kemudian bobotnya akan dilanjutkan ke *output layer* untuk memprediksi data masukan.

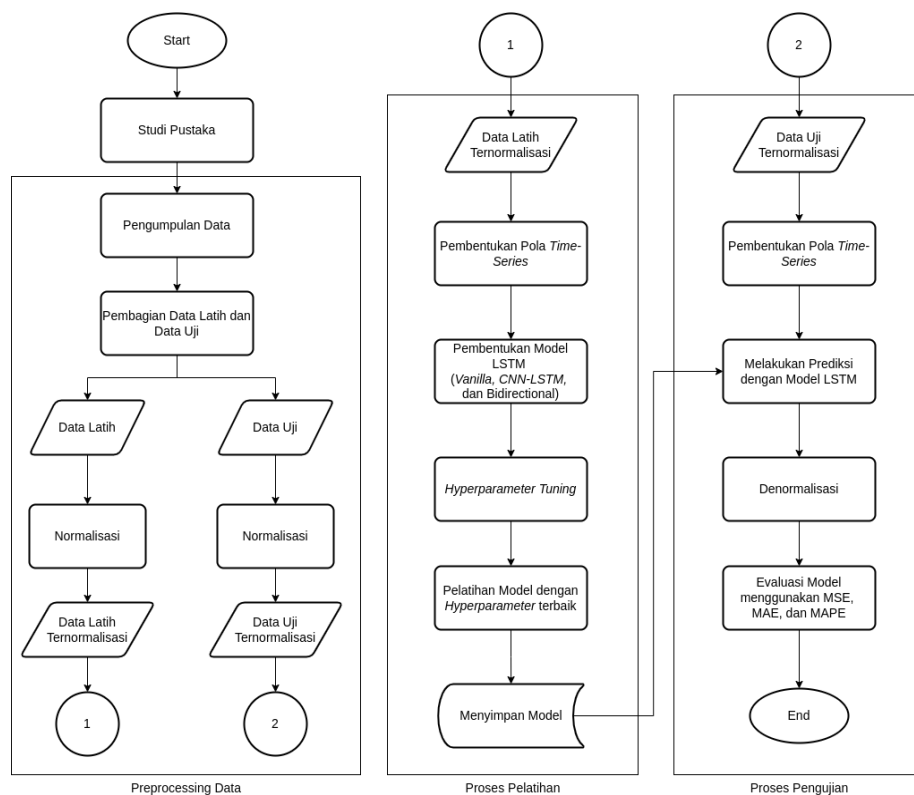
Setelah dilakukan pembentukan pembentukan struktur jaringan syaraf tiruan untuk masing-masing jenis LSTM. Hal selanjutnya yang dilakukan adalah melakukan *hyperparameter tuning* untuk mendapatkan kombinasi jumlah node pada masing-masing layer serta nilai *learning rate* terbaik untuk setiap arsitektur LSTM.

#### 4. Proses Pengujian

Pada proses pengujian, dilakukan uji performa terhadap masing-masing arsitektur yang telah dilatih dengan *hyperparameter* terbaik yang didapatkan dari hasil *hyperparameter tuning*. Pengujian dilakukan menggunakan data uji yang telah dibagi pada proses pembagian data latih dan data uji. Kemudian performa model dihitung berdasarkan *metrics* yang telah ditentukan, antara lain MSE, RMSE, MAE, dan MAPE.

#### 5. Alur Penelitian

Langkah-langkah penelitian digambarkan pada *flowchart* pada Gambar 3.1.



Gambar 3. 1 Langkah-langkah penelitian

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Studi Pustaka dan Pengumpulan Data

Pada penelitian ini, dataset yang digunakan adalah data harian penutupan harga saham PT. Indofood CBP Sukses Makmur dengan kode saham ICBP dari tanggal 3 April 2017 hingga 1 April 2022. Dataset diambil dari yahoo.finance.com yang merupakan website yang menyediakan berbagai informasi mengenai dunia finansial baik berupa data maupun berita. Berikut adalah grafik dari pergerakan harga saham PT. Indofood CBP Sukses Makmur.



Gambar 4. 1 Grafik pergerakan harga saham ICBP

Data pergerakan harga penutupan saham ICBP dari tanggal 3 April 2017 hingga 1 April 2022 didapatkan nilai rata-rata harga saham sebesar Rp9.453 per lembar saham. Harga tertinggi tercatat pada tanggal 8 Oktober 2019 senilai Rp12.400 per lembar saham dan harga terendah pada tanggal 25 Maret 2022 senilai Rp7.250 per lembar saham.

Data harga penutupan harian saham PT Indofood CBP Sukses Makmur dari dataset diuraikan pada Tabel 4.1.

Tabel 4. 1 Harga penutupan harian saham ICBP

<b>Date</b>	<b>Close</b>
2017-04-03	8425.0
2017-04-04	8400.0
2017-04-05	8400.0
2017-04-06	8225.0
2017-04-07	8175.0
...	...
2022-03-28	7275.0
2022-03-29	7300.0
2022-03-30	7375.0
2022-03-31	7350.0
2022-04-01	7525.0

## 4.2 Preprocessing Data

### 4.2.1 Normalisasi

Normalisasi dilakukan dalam rangka untuk meminimalkan error dengan mengubah data aktual menjadi data dengan rentang [0,1]. Teknik normalisasi yang digunakan adalah *min-max scaling*. Rumus *min-max scaling* yang digunakan pada tahap ini seperti pada Persamaan 2.1. Berikut adalah contoh normalisasi data dengan teknik *min-max scaling* untuk.

$$\begin{aligned}
 X'_1 &= \frac{X_1 - X_{min}}{X_{max} - X_{min}} = \frac{8425 - 7250}{12400 - 7250} = 0,2281 \\
 X'_2 &= \frac{X_2 - X_{min}}{X_{max} - X_{min}} = \frac{8400 - 7250}{12400 - 7250} = 0,2233 \\
 X'_3 &= \frac{X_3 - X_{min}}{X_{max} - X_{min}} = \frac{8400 - 7250}{12400 - 7250} = 0,2233 \\
 X'_4 &= \frac{X_4 - X_{min}}{X_{max} - X_{min}} = \frac{8225 - 7250}{12400 - 7250} = 0,1893 \\
 X'_5 &= \frac{X_5 - X_{min}}{X_{max} - X_{min}} = \frac{8175 - 7250}{12275 - 7250} = 0,1796
 \end{aligned}$$

### 4.2.2 Pembagian Data Latih dan Data Uji

Dataset yang digunakan dalam penelitian ini akan dibagi menjadi dua bagian. Data pertama, yaitu data latih digunakan sebagai masukan untuk pelatihan model. Sedangkan data kedua, yaitu data uji digunakan sebagai data pengujian untuk melihat performa model terhadap data yang belum pernah digunakan sebagai masukan pada pelatihan.

Data akan dibagi menjadi data latih dan data uji dengan menggunakan 3 kombinasi proporsi data, yaitu 80:20, 70:30, dan 60:40. Total jumlah data untuk data latih dan data uji dapat dilihat pada Tabel 4.2.

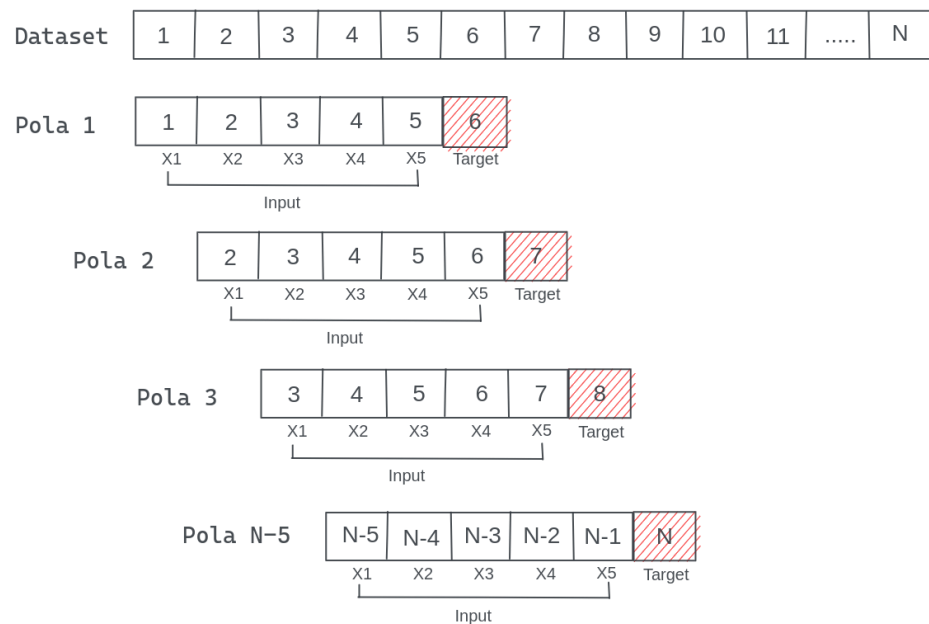
Tabel 4. 2 Pembagian data latih dan data uji

Kombinasi	Persentase Data	Jumlah Data
1	80%	1461
	20%	364
2	70%	1279
	30%	546
3	60%	1096
	40%	729

Pembagian data latih dan data uji bertujuan untuk mengetahui apakah model dapat bekerja dengan baik dengan data yang tidak pernah dilihat ketika melakukan pelatihan. Proses pelatihan dan pengujian menggunakan model akan terus dilakukan hingga didapatkan hasil yang optimal.

### 4.2.3 Struktur Pola *Time Series*

Dataset dalam pelatihan dan pengujian data *time series* pada penelitian ini memiliki struktur dan pola yang terdiri dari 5 data input dan 1 data target. Data input terdiri atas urutan 5 hari data harga saham dan data target adalah data hari ke-6 dari urutan yang akan menjadi acuan model sebagai hasil prediksi data input. Berikut adalah ilustrasi dari pola *time series* pada Gambar 4.2 dengan inputan berupa 5 nilai.



Gambar 4. 2 Ilustrasi pola *time series*

Sebagai contoh, pada data input pertama yaitu urutan harga dari hari Senin tanggal 3 April 2017 hingga hari Jumat tanggal 7 April 2017, sehingga data target adalah data harga pada hari Senin tanggal 8 April 2017. Data input dan data target disajikan dalam Tabel 4.3 berikut dengan penjelasan seperti Gambar 4.2.



Tabel 4. 3 Pola *time series*


X1	X2	X3	X4	X5	Target
0.2281	0.2233	0.2233	0.1893	0.1796	0.1796
0.2233	0.2233	0.1893	0.1796	0.1796	0.1796
0.2233	0.1893	0.1796	0.1796	0.1796	0.1796
...	...	...	...	...	...
0.3301	0.3592	0.3592	0.3592	0.3834	0.3543
0.3592	0.3592	0.3592	0.3834	0.3543	0.3786
0.3592	0.3592	0.3834	0.3543	0.3786	0.3301

### 4.3 Struktur Jaringan Syaraf Tiruan

Pada penelitian ini akan dilakukan *hyperparameter tuning* terhadap struktur jaringan syaraf tiruan menggunakan *random search tuner*. *Tuner* akan melakukan pelatihan dengan berbagai kombinasi jumlah *node* pada *hidden layer* dengan nilai dari 32-512 dengan kelipatan 32 serta *learning rate* dengan kombinasi nilai [0,01, 0,001, 0,0001]. *Tuner* akan melakukan percobaan sebanyak 15 kali untuk mendapatkan kombinasi jumlah *node* dan *learning rate* yang optimal untuk model.

#### 4.3.1 Vanilla LSTM

*Vanilla LSTM* model adalah model LSTM yang hanya memiliki satu *hidden layer* dari jaringan LSTM dan sebuah *output layer* sebagai pembuat prediksi. Berikut ditampilkan jaringan *Vanilla LSTM* yang digunakan untuk penelitian ini pada Gambar 4.3.




Gambar 4. 3 Struktur jaringan *vanilla* LSTM

Pada struktur *Vanilla LSTM* akan dilakukan *tuning* untuk menentukan jumlah *node* optimal pada *hidden layer* “lstm\_1” dengan nilai antara 32-512 dengan kelipatan 32. Selain menentukan jumlah *node* optimal, *tuning* juga akan menentukan *learning rate* optimal dengan kombinasi nilai [0,01, 0,001, 0,0001].

### 4.3.2 CNN-LSTM

*Convolutional Neural Network* (CNN) adalah jenis *neural network* yang dikembangkan untuk mengelola data dua dimensi seperti gambar. CNN juga dapat digunakan secara efektif untuk mengekstrak dan mempelajari informasi data urutan satu dimensi seperti *univariate time series*.

Model CNN dapat juga disatukan dengan LSTM dimana CNN digunakan untuk mengekstrak dan menginterpretasikan data masukan untuk LSTM model. Model *hybrid* ini disebut sebagai CNN-LSTM. Berikut susunan model CNN-LSTM pada Gambar 4.4.

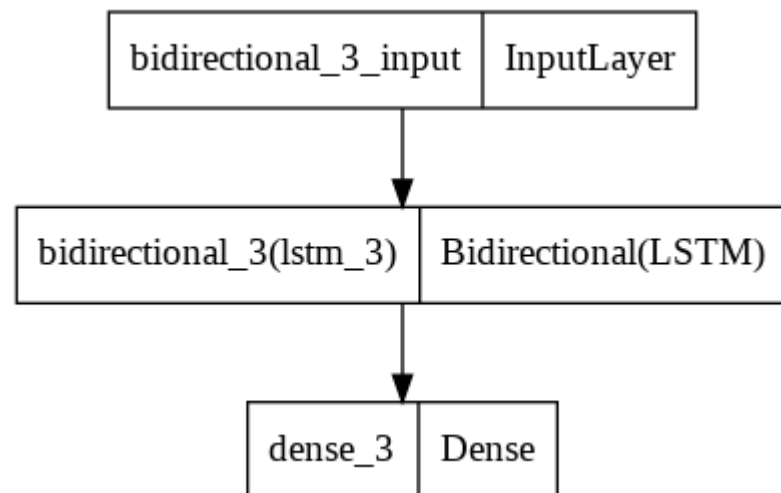


Gambar 4. 4 Struktur jaringan CNN-LSTM

Pada arsitektur CNN-LSTM akan dilakukan *tuning* untuk menentukan jumlah node pada layer “conv1d\_1” dan layer “lstm\_1” dengan kombinasi node antara 32 hingga 512 dengan kelipatan 32. Kemudian akan dilakukan juga *tuning* untuk *learning rate* dengan kombinasi nilai [0,01, 0,001, 0,0001]. *Tuning* akan dilakukan sebanyak 15 kali untuk mendapatkan kombinasi jumlah *node* dan *learning rate* untuk hasil yang paling optimal.

#### 4.3.3 *Bidirectional LSTM*

*Bidirectional LSTM* memungkinkan model LSTM untuk mempelajari urutan data secara bolak-balik dan menggabungkan kedua interpretasi tersebut untuk menghasilkan prediksi. Dalam penelitian ini akan diterapkan layer *bidirectional LSTM* pada *hidden layer*. Berikut ditampilkan struktur jaringan *bidirectional LSTM* pada Gambar 4.5.



Gambar 4. 5 Struktur jaringan *bidirectional LSTM*

Pada arsitektur *bidirectional LSTM* akan dilakukan *tuning* dalam menentukan jumlah *node* untuk *hidden layer* “*bidirectional\_3*” dengan kombinasi nilai antara 32 hingga 512 dengan kelipatan 32. *Tuning* juga akan melakukan kombinasi untuk mencari *learning rate* terbaik untuk kombinasi [0,01, 0,001, 0,0001]. Seperti pada struktur model *vanilla* dan CNN-LSTM, *tuning* akan dilakukan sebanyak 15 kali untuk mendapatkan kombinasi jumlah *node* dan *learning rate* untuk hasil yang paling optimal.

#### 4.4 Proses Percobaan dan Pelatihan

Proses percobaan yang dilakukan adalah mencari model terbaik menggunakan *hyperparameter tuning* dengan menggunakan *random search tuner* dimana *tuner* akan melakukan pelatihan sebanyak 15 kombinasi *hyperparameter* yaitu jumlah *node* pada *hidden layer* dan juga *learning rate* yang berbeda untuk mendapatkan model dengan hasil paling optimal.

##### 4.4.1 Vanilla LSTM

Inisiasi *hyperparameter* untuk model *vanilla LSTM* yaitu sebagai berikut.

“*lstm\_1*” = 32 hingga 512 dengan kelipatan 32.

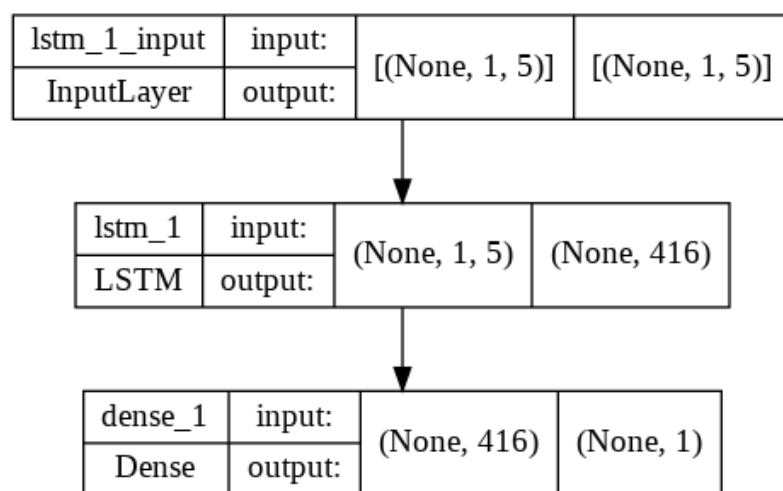
*learning rate* = 0,01, 0,001, 0,0001.

Berikut ditampilkan 15 kali kombinasi percobaan terhadap model *Vanilla LSTM* yang diurutkan berdasarkan hasil yang terbaik pada Tabel 4.4.

Tabel 4. 4 Hasil *hyperparameter tuning vanilla* LSTM

Urutan	Jumlah <i>Node LSTM</i>	<i>Learning rate</i>	MSE
1	416	0,01	0,000629
2	288	0,01	0,0006307
3	320	0,01	0,0006308
4	256	0,01	0,0006334
5	480	0,01	0,0003337
6	352	0,01	0,0006349
7	64	0,01	0,0006434
8	192	0,001	0,0006801
9	480	0,001	0,0006813
10	224	0,001	0,0006829
11	256	0,001	0,0006859
12	448	0,001	0,0007029
13	64	0,001	0,000816
14	512	0,0001	0,0009832
15	384	0,0001	0,0009859

Berdasarkan hasil percobaan terhadap jumlah *node hidden layer* dan *learning rate* untuk arsitektur *vanilla LSTM*, didapatkan hasil terbaik yaitu kombinasi jumlah *node* 416 dan *learning rate* 0,01 dengan loss *mean squared error* bernilai 0,000629 untuk data training yang sudah dilakukan denormalisasi. Visualisasi model dengan jumlah *node* dan *learning rate* terbaik untuk *vanilla LSTM* dapat dilihat pada Gambar 4.6.



Gambar 4. 6 Arsitektur vanilla LSTM dengan *hyperparameter* terbaik

Selanjutnya adalah membangun model dengan menggunakan jumlah *node hidden layer* dan *learning rate* terbaik dengan *epoch* berjumlah 50. Hasil pelatihan model didapatkan performa terhadap data latih yang telah dinormalisasi seperti pada Tabel 4.5.

Tabel 4. 5 Performa *vanilla LSTM* terhadap data latih ternormalisasi

Kombinasi	MSE	MAE	$R^2$
80:20	0,000702	0,016287	0,982747
70:30	0,000694	0,014908	0,984531

60:40	0,000703	0,017003	0,985983
-------	----------	----------	----------


Tabel 4.5 adalah performa model terhadap data latih ternormalisasi. Performa tersebut mendekati dengan hasil *hyperparameter tuning* yang telah dilakukan, dimana MSE *hyperparameter tuning* terbaik bernilai 0,000629 dan MSE terbaik pada Tabel 4.5 bernilai 0,000694. Jika dilakukan denormalisasi, performa model terhadap data latih aktual tanpa normalisasi terlihat pada Tabel 4.6.

Tabel 4. 6 Performa *vanilla* LSTM terhadap data latih aktual

<b>Kombinasi</b>	<b>MSE</b>	<b>MAE</b>	<b>R<sup>2</sup></b>
80:20	18611,6667	83,8803	0,9827
70:30	18410,9624	76,7754	0,9845
60:40	14468,06	75,4312	0,9859

Berikut ditampilkan hasil perbandingan terhadap data latih aktual dengan prediksi model untuk 50 data latih pertama pada Gambar 4.7.





Gambar 4. 7 Perbandingan latih aktual dan prediksi vanilla LSTM

#### 4.4.2 CNN-LSTM

Inisiasi *hyperparameter* untuk model *CNN-LSTM* yaitu sebagai berikut.

“lstm\_1” = 32 hingga 512 dengan kelipatan 32.

“conv1d\_1” = 32 hingga 512 dengan kelipatan 32.

*learning rate* = 0,01, 0,001, 0,0001.

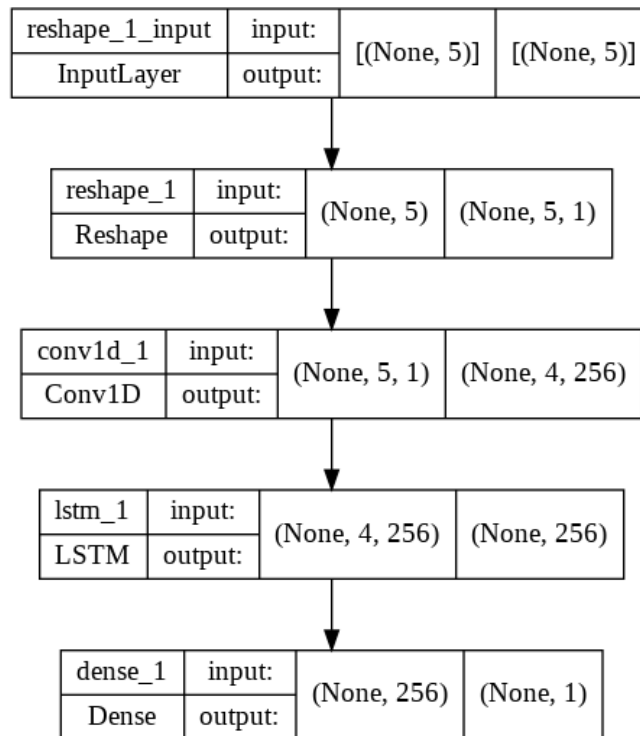
Berikut ditampilkan 15 kali kombinasi percobaan terhadap model *CNN-LSTM* yang diurutkan berdasarkan hasil yang terbaik pada Tabel 4.7.

Tabel 4. 7 Hasil *hyperparameter tuning* CNN-LSTM

Urutan	Jumlah Node CNN	Jumlah Node LSTM	Learning rate	MSE
1	256	256	0,001	0,0006181
2	160	448	0,001	0,0006193

3	352	480	0,001	0,0006211
4	256	224	0,001	0,0006215
5	288	96	0,001	0,0006211
6	64	320	0,01	0,0006281
7	416	96	0,001	0,0006293
8	352	64	0,001	0,0006301
9	288	64	0,001	0,0006346
10	384	128	0,01	0,0006353
11	160	512	0,0001	0,0007167
12	192	256	0,0001	0,0007856
13	480	64	0,0001	0,0007951
14	64	160	0,0001	0,001021
15	64	64	0,0001	0,0010762

Berdasarkan hasil percobaan pada Tabel 4.6 didapatkan kombinasi terbaik dengan jumlah *node* untuk *layer CNN* dan *layer LSTM* adalah 256 dan *learning rate* yaitu 0,001 dengan hasil MAE 0,0006181 untuk data training yang sudah denormalisasi. Visualisasi model dengan jumlah *node* dan *learning rate* terbaik untuk CNN-LSTM dapat dilihat pada Gambar 4.8.



Gambar 4. 8 Arsitektur CNN-LSTM dengan *hyperparameter* terbaik

Struktur kombinasi jumlah *node* dan *learning rate* terbaik digunakan untuk melatih model dengan jumlah pelatihan 50 *epoch*. Hasil pelatihan model didapatkan performa untuk data latih seperti terlihat pada Tabel 4.8.

Tabel 4. 8 Performa CNN-LSTM terhadap data latih ternormalisasi


Kombinasi	MSE	MAE	$R^2$
80:20	0,000849	0,020072	0,979118
70:30	0,00073	0,016335	0,983714
60:40	0,000674	0,014694	0,986555

Performa MSE pada Tabel 4.8 mendekati hasil *hyperparameter tuning* yang telah dilakukan, dimana MSE *hyperparameter tuning* terbaik bernilai 0,0006181 dan MSE terbaik pada Tabel 4.8 bernilai 0,000674. Jika dilakukan denormalisasi, performa model terhadap data latih aktual tanpa normalisasi terlihat pada Tabel 4.9.

Tabel 4. 9 Performa CNN-LSTM terhadap data latih aktual

Kombinasi	MSE	MAE	$R^2$
80:20	22516,0822	103,3689	0,979118
70:30	19371,3779	84,136	0,983714
60:40	17875,0917	75,6744	0,986555

Berikut ditampilkan perbandingan 50 data pertama data latih aktual dengan hasil prediksi model *CNN-LSTM* pada Gambar 4.9.



Gambar 4. 9 Perbandingan data latih aktual dan prediksi CNN-LSTM

#### 4.4.3 Bidirectional-LSTM

Inisiasi *hyperparameter* untuk model *bidirectional LSTM* yaitu sebagai berikut.

“bidirectional\_3” = 32 hingga 512 dengan kelipatan 32.

*learning rate* = 0,01, 0,001, 0,0001.

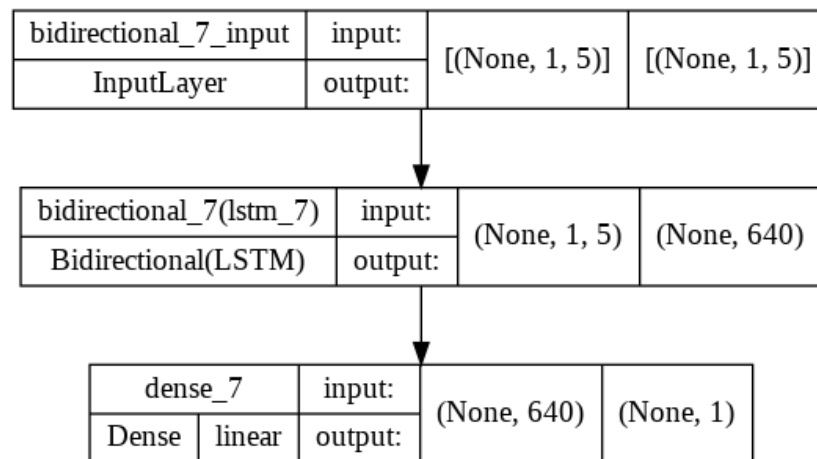
Berikut ditampilkan 15 kali kombinasi percobaan terhadap model *bidirectional LSTM* yang diurutkan berdasarkan hasil yang terbaik pada Tabel 4.10.

Tabel 4. 10 Hasil *hyperparameter tuning bidirectional LSTM*

Urutan	Jumlah Node Bi-LSTM	Learning rate	MSE
1	320	0,01	0,000626
2	256	0,01	0,0006272
3	288	0,01	0,000628
4	416	0,01	0,0006299
5	480	0,01	0,00631
6	64	0,01	0,000632
7	352	0,01	0,0006346
8	480	0,001	0,0006557
9	448	0,001	0,0006614
10	224	0,001	0,0006702

11	192	0,001	0,0006733
12	256	0,001	0,0006736
13	64	0,001	0,0007017
14	512	0,0001	0,0008844
15	384	0,0001	0,0009277

Berdasarkan hasil dari *hyperparameter tuning* didapatkan kombinasi terbaik untuk struktur *Bidirectional LSTM* yaitu jumlah *node* untuk *hidden layer* adalah 320 dan *learning rate* 0,01 dengan hasil MSE adalah 0,000626. Visualisasi model dengan jumlah *node* dan *learning rate* terbaik untuk CNN-LSTM dapat dilihat pada Gambar 4.10.



Gambar 4. 10 Arsitektur bidirectional LSTM dengan *hyperparameter* terbaik

Struktur yang didapatkan tersebut kemudian dilakukan pelatihan ulang menggunakan data latih sebanyak 50 *epoch*. Hasil pelatihan menghasilkan performa model untuk data latih seperti diuraikan pada Tabel 4.11.

Tabel 4. 11 Performa *bidirectional* LSTM terhadap data latihan ternormalisasi


Kombinasi	MSE	MAE	R <sup>2</sup>
80:20	0,0008	0,0217	0,97806
70:30	0,0266	0,0155	0,98414
60:40	0,0006	0,0162	0,986348

Berikut performa model terhadap data latihan yang tidak dinormalisasi terlihat pada Tabel 4.12.

Tabel 4. 12 Performa *bidirectional* LSTM terhadap data latihan aktual

Kombinasi	MSE	MAE	R <sup>2</sup>
80:20	23659,0348	112.1329	0,97806
70:30	18875,815	80,096	0,98414
60:40	18162,5299	83.8808	0,986348

Berikut ditampilkan perbandingan 50 data pertama data latihan aktual dengan hasil prediksi dari model *bidirectional LSTM* pada Gambar 4.11.



Gambar 4. 11 Perbandingan data latih aktual dengan prediksi *bidirectional* LSTM

Model Vanilla LSTM dan CNN-LSTM yang dilatih menggunakan 60% dataset memiliki performa memorisasi (pengujian terhadap data latih) terbaik dibandingkan model yang dilatih menggunakan 70% dan 80% dataset. Sementara model Bidirectional LSTM memiliki memorisasi terbaik untuk model yang dilatih menggunakan 70% dataset dibanding model yang dilatih menggunakan 60% dan 80% dataset.

Berikut ditampilkan perbandingan masing-masing jenis LSTM dengan memori terbaik pada Tabel 4.13.

Tabel 4. 13 Perbandingan performa tiga jenis LSTM terbaik terhadap data latih

Jenis LSTM	MSE	MAE	$R^2$
Vanilla (60:40)	14468,06	75,4312	0,9859
CNN-LSTM (60:40)	17875,0917	75,6744	0,986555
Bidirectional (70:30)	18875,815	80,096	0,98414



Dari ketiga model LSTM di atas didapatkan model *Vanilla* memiliki hasil terbaik berdasarkan MSE dan MAE karena memiliki nilai yang paling rendah untuk metrik tersebut dibanding nilai lainnya. Namun, terhadap  $R^2$ , CNN-LSTM memiliki nilai paling tinggi yaitu 98,6555% (0,986555).

## 4.5 Proses Pengujian


### 4.5.1 Vanilla LSTM

Menggunakan jaringan yang sama untuk kombinasi *hyperparameter* terbaik dari hasil *hyperparameter tuning* yaitu jumlah *node* pada *hidden layer* 416 dan *learning rate* 0,01 dan pelatihan yang seperti dilakukan pada Sub Bab 4.4.1. Dilakukan simulasi terhadap data uji. Didapatkan hasil sebagai berikut yang diuraikan pada Tabel 4.14.

Tabel 4. 14 Performa *vanilla* LSTM terhadap data uji

Kombinasi	MSE	MAE	$R^2$
80:20	20614,8537	98,6853	0.878271
70:30	14468,06	75,4312	0.963433
60:40	18719,7134	96,0667	0.96434

Berikut ditampilkan perbandingan data uji aktual terhadap hasil prediksi model *Vanilla LSTM* pada Gambar 4.12.



Gambar 4. 12 Perbandingan data uji dengan prediksi *vanilla* LSTM


#### 4.5.2 CNN LSTM

Proses yang sama seperti yang dilakukan pada model *Vanilla LSTM*. *CNN LSTM* juga dilakukan lagi pelatihan dengan struktur kombinasi terbaik yang didapatkan dari hasil *hyperparameter tuning*, dengan performa untuk data latih pada Tabel 4.9. Kemudian, dilakukan simulasi terhadap data uji, didapatkan hasil performa yang diuraikan pada Tabel 4.15.

Tabel 4. 15 Performa CNN-LSTM terhadap data uji

Kombinasi	MSE	MAE	$R^2$
80:20	12919,4514	75,2075	0,924641
70:30	13338,0652	74,1365	0,96648
60:40	15661,4417	77,0031	0,970298

Berikut hasil perbandingan data uji aktual dengan hasil prediksi model pada Gambar 4.13.



Gambar 4. 13 Perbandingan data uji dengan prediksi CNN-LSTM


### 4.5.3 Bidirectional LSTM

Struktur *bidirectional LSTM* terbaik berdasarkan hasil *hyperparameter tuning* yaitu jumlah *node* pada *hidden layer* adalah 320 dengan *learning rate* 0,01. Struktur terbaik tersebut dilakukan pelatihan ulang dengan jumlah epoch sebanyak 50 dan didapatkan performa model terhadap data latih seperti pada Tabel 4.12. Kemudian, dengan model yang sama, dilakukan simulasi prediksi terhadap data uji dengan hasil yang diuraikan pada Tabel 4.16.

Tabel 4. 16 Performa model terhadap data uji

Kombinasi	MSE	MAE	$R^2$
80:20	19548,01195	94,3543	0,884571
70:30	16195,3374	79,3791	0,959068
60:40	17457,6515	85,9754	0,966744

Berikut adalah hasil perbandingan data uji aktual dengan hasil prediksi model pada Gambar 4.14.



Gambar 4. 14 Perbandingan data uji dengan prediksi

Berdasarkan hasil pengujian, didapatkan bahwa model dengan performa generalisasi terbaik terhadap metrik MSE dan MAE untuk masing-masing jenis LSTM adalah model dengan kombinasi pelatihan data latih dan data uji 70:30. Hal tersebut berbeda dengan uji memorisasi menggunakan data latih, dimana model terbaik untuk Vanilla dan CNN-LSTM adalah model yang dilatih menggunakan 60% dataset, namun untuk Bidirectional adalah model yang dilatih menggunakan 70%. Berikut ditampilkan perbandingan data hasil pengujian generalisasi terhadap data uji untuk setiap jenis model dengan kombinasi data latih dan data uji 70:30 dan 60:40 pada Tabel 4.17.

Tabel 4. 17 Performa 3 jenis LSTM terbaik terhadap data uji

Kombinasi data latih:data uji	Jenis Model	MSE	MAE	$R^2$
70:30	Vanilla	14468,06	75,4312	0.963433
	CNN-LSTM	13338,0652	74,1365	0,96648

	Bidirectional	16195,3374	79,3791	0,959068
60:40	Vanilla	18719,7134	96,0567	0.96434
	CNN-LSTM	15661,4416	77,0031	0,970298
	Bidirectional	17457,6515	85,9754	0,966744

Walaupun terhadap matrik MSE dan MAE model yang dilatih dengan 70% dataset memiliki performa yang bagus untuk generalisasi terhadap data uji. Namun, semua jenis model LSTM yang dilatih menggunakan 60% dataset memiliki nilai  $R^2$  yang paling tinggi.

#### 4.6 Analisis Model Terbaik

Model terbaik untuk setiap kombinasi pembagian data latih dan data uji adalah CNN-LSTM. Setelah dilakukan konfigurasi menggunakan nilai *hyperparameter* yang didapatkan dari proses *hyperparameter tuning*, yaitu jumlah *node layer* CNN adalah 256, jumlah *node* untuk *layer* LSTM yang juga berjumlah 256, dan dengan *learning rate* 0,001. Kemudian dilakukan pelatihan terhadap kombinasi data latih dan data uji, yaitu kombinasi 80:20, 70:30, dan 60:40.

Untuk performa model LSTM dengan kombinasi data pelatihan dan data uji 70:30, berdasarkan Tabel 4.8 didapatkan  $R^2$  terhadap data latih yaitu sebesar 98,3% yang berarti 98,3% variasi dalam data prediksi berkorelasi dengan baik terhadap *feature* atau *input*, namun 1,7% dipengaruhi oleh faktor lain. Begitupun terhadap data uji berdasarkan Tabel 4.17 perolehan nilai  $R^2$  yaitu 96,6%.

Berdasarkan Tabel 4.13, model CNN-LSTM yang dilatih terhadap 60% dataset memiliki nilai  $R^2$  yaitu 98,65% dan berdasarkan Tabel 4.17 nilai  $R^2$  terhadap data uji yaitu 97,02% yang berarti 97,02% variasi dalam data prediksi berkorelasi dengan baik terhadap *feature* atau *input* sedangkan 2,98% dipengaruhi oleh faktor lainnya.

Selanjutnya dilakukan *permutation feature importance*, yaitu teknik untuk menentukan pengaruh setiap *feature* terhadap model. *permutation feature importance* ini didefinisikan sebagai penurunan skor model ketika nilai fitur tunggal diacak secara acak. Prosedur ini memutuskan hubungan antara *feature* dan target, sehingga penurunan skor model menunjukkan seberapa banyak model tergantung pada *feature* tertentu (Anggara dan Supandi, 2022).

CNN-LSTM adalah *black-box* model, yang berarti sangat sulit untuk menginterpretasikan secara eksplisit bagaimana model mendapatkan hasil prediksinya. Maka dari itu digunakan *permutation feature importance* untuk mencari *feature* yang sangat berpengaruh terhadap model. *Permutation feature importance weights* didapatkan dari pengurangan nilai model dengan rata-rata skor setelah *feature* diubah secara acak, sehingga semakin besar *weight*-nya maka semakin berpengaruh *feature* tersebut terhadap model.

Berikut ditampilkan *weight* menggunakan metrik  $R^2$  dari masing-masing *feature* terhadap data uji untuk model CNN-LSTM pada Tabel 4.18 dan Tabel 4.19.

Tabel 4. 18 Permutation importance CNN-LSTM 70:30 menggunakan metrik  $R^2$

Weight	Feature
1,2338 $\pm$ 0,0601	X5

$0,0281 \pm 0,0028$	X4
$0,0071 \pm 0,0013$	X3
$0,0006 \pm 0,0002$	X1
$0,0002 \pm 0,0001$	X2

Tabel 4. 19 Permutation importance CNN-LSTM 60:40 menggunakan metrik  $R^2$

Weight	Feature
$1,1094 \pm 0,1185$	X5
$0,0355 \pm 0,0074$	X4
$0,0113 \pm 0,0016$	X3
$0,0022 \pm 0,0011$	X2
$0,0003 \pm 0,0003$	X1

Pada Tabel 4.18 terlihat pada yang paling mempengaruhi model CNN-LSTM adalah *feature* X5, dan yang paling tidak berpengaruh terhadap model adalah *feature* X2. Berdasarkan Tabel 4.19 CNN-LSTM terhadap kombinasi data latih 60:40, juga didapatkan *feature* yang paling berpengaruh terhadap model adalah X5 dan yang paling tidak berpengaruh terhadap prediksi model adalah *feature* X1.

## BAB V

### PENUTUP

#### 5.1 Kesimpulan

Berdasarkan hasil dari penelitian ini, dapat disimpulkan beberapa hal sebagai berikut:

1. Nilai MSE dan MAE yang dihasilkan untuk semua jenis model LSTM baik vanilla, CNN-LSTM dan bidirectional LSTM terhadap data uji yakni untuk MSE dengan rentang dari 16195,3374 hingga 13338,0652 dan untuk MAE dengan rentang dari 79,3791 hingga 74,1365. Baik untuk nilai MSE dan MAE yang dihasilkan tergolong baik dalam kemampuan untuk memprediksi karena nilai yang tergolong kecil. Dibuktikan juga juga dengan nilai  $R^2$  yang mempunyai rentang dari 95,9% hingga 96,6%. Nilai  $R^2$  tersebut mendekati 100% yang berarti model sangat bagus dalam memprediksi harga saham.
2. Jenis LSTM terbaik terhadap data uji dalam memprediksi saham adalah CNN-LSTM perolehan nilai MAE sebesar 74,1365 dan  $R^2$  sebesar 96,6% yang menunjukkan akurasi yang sangat tinggi.
3. Struktur jaringan terbaik yang diraih dalam penelitian ini untuk CNN-LSTM yaitu jumlah *node* untuk *layer CNN* adalah 256, *layer LSTM* adalah 256 dan *learning rate* adalah 0,001 dengan jumlah epoch 50.
4. Pembagian data terbaik untuk data latih dan data uji adalah 70% untuk data latih dan 30% untuk data uji.



## 5.2 Saran

Berdasarkan hasil penelitian, model LSTM yang diterapkan masih terbilang sederhana karena *feature* yang digunakan berasal hanya dari data penutupan harga saham ICBP. Oleh karena itu penulis menyarankan untuk penelitian berikutnya yang dapat dilakukan adalah meningkatkan kompleksitas model LSTM serta penggunaan *feature* untuk meningkatkan akurasi model prediksi harga saham ICBP.

## DAFTAR PUSTAKA

- Anggara, Y. and Supandi, E. D. (2022) 'Jakarta Composite Index Model Before and During COVID-19 Using CNN-LSTM', *Proceedings of the International Conference on Science and Engineering (ICSE-UIN-SUKA 2021)*, 211(January). doi: 10.2991/aer.k.211222.036.
- Aprian, B. A., Azhar, Y. and Nastiti, V. R. S. (2020) 'Prediksi Pendapatan Kargo Menggunakan Arsitektur Long Short Term Memory', *Jurnal Komputer Terapan*, 6(2), pp. 148–157.
- Cahyadi, R., Damayanti, A. and Aryadani, D. (2020) 'Recurrent Neural Network (RNN) dengan Long Short Term Memory (LSTM) untuk analisis sentimen data instagram', *Jurnal Informatika dan Komputer*, 5(1), pp. 1–9. Available at: <https://ejournal.akakom.ac.id/index.php/jiko/article/view/407>.
- Cai, C. *et al.* (2021) 'Short-term load forecasting based on deep learning bidirectional lstm neural network', *Applied Sciences (Switzerland)*, 11(17). doi: 10.3390/app11178129.
- Goodfellow Ian, Bengio Yoshua, C. A. (2016) 'Deep Learning - Ian Goodfellow, Yoshua Bengio, Aaron Courville - Google Books', *MIT Press*.
- Prasetyawan, D. and 'Uyun, S. (2020) 'Penentuan Emosi pada Video dengan Convolutional Neural Network', *JISKA (Jurnal Informatika Sunan Kalijaga)*, 5(1), pp. 23–35. doi: 10.14421/jiska.2020.51-04.
- Sabar Sautomo and Hilman Ferdinandus Pardede (2021) 'Prediksi Belanja Pemerintah Indonesia Menggunakan Long Short-Term Memory (LSTM)', *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 5(1), pp. 99–106. doi: 10.29207/resti.v5i1.2815.
- Siarni-Namini, S., Tavakoli, N. and Namin, A. S. (2019) 'The Performance of LSTM and BiLSTM in Forecasting Time Series', *Proceedings - 2019 IEEE International Conference on Big Data, Big Data 2019*, pp. 3285–3292. doi: 10.1109/BigData47090.2019.9005997.
- Sumarjaya, I. W. (2016) 'Modul Analisis Deret Waktu', *Fakultas Matematika Dan Ilmu Pengetahuan Alam Universitas Udayana*.

- Ta, V. D., Liu, C. M. and Tadesse, D. A. (2020) 'Portfolio Optimization-Based Stock Prediction Using Long-Short Term Memory Network in Quantitative Trading', *Applied Sciences (Switzerland)*, 10(2).
- Van Houdt, G., Mosquera, C. and Nápoles, G. (2020) 'A review on the long short-term memory model', *Artificial Intelligence Review*, 53(8), pp. 5929–5955. doi: 10.1007/s10462-020-09838-1.
- Wiranda, L. and Sadikin, M. (2019) 'Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma', *Jurnal Nasional Pendidikan Teknik Informatika*, 8(3), pp. 184–196.

**CIRRICULUM VITAE**

Nama Lengkap : Irfan Chairurrachman

Jenis Kelamin : Laki-laki

Alamat asal : Bumi Berua Indah Blk A7 No.4, Makassar, Sulawesi Selatan.

Email : [irfanchairurrachman@gmail.com](mailto:irfanchairurrachman@gmail.com)

No.Handphone : 082199590357

Nama Ayah : Ir. Zulmanwardi, M.Si.

Nama Ibu : Yenni Suryati